

詹勇

(+86) 188-5660-3434 · 3446914219@qq.com · GitHub | CSDN @daetz-coder · 浙江-杭州

个人简介

计算机技术硕士在读，聚焦 **AI Agent 系统设计**、**RAG 与 LLM 应用工程化**。独立完成 Agent 运行时评估平台、RAG 知识库系统（Milvus + BM25 混合检索 + RecursiveCharacterTextSplitter 多格式文档解析），深入掌握 LangGraph 工作流编排、LLM-as-Judge 评估方法与 Docker 容器化部署，具备多模型 Consensus 实践经验。

教育背景

浙江理工大学, 计算机技术硕士（在读） 2024.9 - 至今

一等奖优秀奖学金 (1 次), 二等奖优秀奖学金 (1 次)

嘉兴大学, 软件工程学士 2020.9 - 2024.6

校级优秀毕业生, 浙江省政府奖学金 (1 次), 学习优秀奖学金 (6 次)

学术成果

- **Yong Zhan**, Xiangyang Li, et al. “W-MSTC: A Window Based Multi-Scale Temporal Cross Attention Method for Few-Shot Modulation Recognition,” *IEEE Communications Letters*, 2025.（第一作者）
- Congyuan Xu, **Yong Zhan**, et al. “Multimodal Fusion Based Few-Shot Network Intrusion Detection System,” *Scientific Reports*, 2025.（第二作者）

技术能力

- **Agent / RAG**: LangGraph、StateGraph、Human-in-the-Loop、Checkpoint、Tool Calling、LLM-as-Judge、Milvus、BM25、BGE-M3、RRF、RecursiveCharacterTextSplitter、PydanticOutputParser
- **LLM 应用**: DeepSeek / GLM-4 / Qwen-Plus 多模型共识对比、Prompt/Context Engineering、SSE 流式输出、Token 成本优化
- **全栈工程**: Python / FastAPI / Async SQLAlchemy / Pydantic / Vue3 / TypeScript / ElementPlus / ECharts / Milvus / Docker / Git / Alembic

项目经历

Agent Runtime Evaluation Platform：AI Agent 运行时质量评估平台 Python / FastAPI / LangGraph / Vue3 2025.3 - 至今

- 六维评估体系（17 项子指标 + 幻觉检测）：Planning / Tactical / Tool Use / Memory / Replan / Retrieval (relevance / evidence_accuracy / coverage + hallucination_detected)，加权聚合（20/20/15/15/15/15）+ 四档标定（ $\geq 80/\geq 60/\geq 40$ ），6 条轨迹 $\times$ 6 评估器并行（asyncio.gather， $\sim 15s$ ），综合分单调递减 **93.1 $\rightarrow$ 92.0 $\rightarrow$ 81.0 $\rightarrow$ 54.4 $\rightarrow$ 27.8 $\rightarrow$ 20.0**，成本 **¥0.012**（DeepSeek vs GPT-4o 低 27x）
- 多模型共识 + 零侵入 SDK + 全链路可观测：DeepSeek / GLM-4 / Qwen-Plus 三厂商独立评分（mean $\pm$ std），前端多模型对比柱状图；LangGraph Instrument / LLM Proxy / Callback 三种接入模式，独立 SDK (sdk/) 仅需 httpx + langchain-core，一行代码接入；线程安全轨迹采集器，ECharts 雷达图/趋势线/热力图/相关性矩阵可视化 + SQL 聚合分析；Monotonicity Benchmark 产品化，Dashboard 真实数据驱动

Wiki-Agent：AI 驱动的智能知识库系统 LangGraph / FastAPI / Vue3 / Milvus 2025.5 - 至今

- 多格式文档解析 + **RecursiveCharacterTextSplitter**：支持 Markdown/PDF/Word/TXT 自动识别与解析（pypdf/python-docx），LangChain RecursiveCharacterTextSplitter 13 层分隔符分块（500 字符/50 重叠），比手写 chunker 语义边界更稳健
- 三级混合检索（20 条查询基准）：Milvus 向量语义搜索（BGE-M3 + cosine）Top-1=**85.0%** / MRR=**0.91**，BM25 关键词搜索（jieba 分词 + rank_bm25 + 25 词停用词表）Top-1=80.0% / MRR=0.85，Hybrid RRF 倒数秩融合（k=60）Top-1=85.0% / MRR=0.87；三路并行按文档去重保留最高分 chunk
- **4-Node StateGraph + 四路同步**：search $\rightarrow$ respond $\rightarrow$ decide $\rightarrow$ execute，条件路由 + LangGraph interrupt 实现 Human-in-the-Loop CRUD，AsyncSqliteSaver Checkpoint 恢复，PydanticOutputParser 自动提取知识（create/update/delete/none）；Markdown $\rightarrow$ RecursiveCharacterTextSplitter $\rightarrow$ BGE-M3 Embedding $\rightarrow$ Milvus + BM25 + Git 四路实时同步，commit 级回滚 + 一键全量重建，Vue3 向量管理后台可视化管理分块与元数据