

詹勇

(+86) 188-5660-3434 · 3446914219@qq.com · GitHub | CSDN @daetz-coder · 浙江-杭州

个人简介

计算机技术硕士在读，聚焦 **AI Agent 系统设计**、**RAG 与 LLM 应用工程化**。独立完成 Agent 运行时评估平台、RAG 知识库系统（Milvus 向量检索 + BM25 混合搜索）等全栈项目，熟悉 LangGraph 工作流编排、混合检索增强与 LLM-as-Judge 评估方法。

教育背景

浙江理工大学, 计算机技术硕士（在读） 2024.9 - 至今
一等优秀奖学金 (1 次), 二等优秀奖学金 (1 次)
嘉兴大学, 软件工程学士 2020.9 - 2024.6
校级优秀毕业生, 浙江省政府奖学金 (1 次), 学习优秀奖学金 (6 次)

学术成果

- **Yong Zhan**, Xiangyang Li, et al. "W-MSTC: A Window Based Multi-Scale Temporal Cross Attention Method for Few-Shot Modulation Recognition," *IEEE Communications Letters*, 2025. (第一作者)
- Congyuan Xu, **Yong Zhan**, et al. "Multimodal Fusion Based Few-Shot Network Intrusion Detection System," *Scientific Reports*, 2025. (第二作者)

技术能力

- **Agent / RAG**: LangGraph、StateGraph、Human-in-the-Loop、Checkpoint、Tool Calling、LLM-as-Judge、Milvus 向量检索、BM25、BGE-M3、RRF、RecursiveCharacterTextSplitter
- **LLM 应用**: DeepSeek / GLM-4 / Qwen-Plus 多模型共识、Prompt/Context Engineering、SSE 流式输出、Token 优化
- **全栈工程**: Python / FastAPI / Async SQLAlchemy / Pydantic / Vue3 / TypeScript / ElementPlus / ECharts / Milvus / Docker

项目经历

Agent Runtime Evaluation Platform：AI Agent 运行时质量评估平台 Python / FastAPI / LangGraph / Vue3 2025.3 - 至今

- **六维评估体系（17 项子指标 + 幻觉检测）**：Planning（覆盖度/顺序/粒度/完整性）、Tactical（相关性/效率/正确性）、Tool Use（选择质量/参数准确性/结果利用）、Memory（保持力/相关性/一致性）、Replan（触发适当性/适应质量/学习能力）、Retrieval（相关性/证据准确性/覆盖度 + hallucination_detected），加权聚合 + 四档标定（ $\geq 80/\geq 60/\geq 40$ 优秀至较差），6 条不同质量轨迹 $\times$ 6 评估器实测：综合分 **93.1** $\rightarrow$ **92.0** $\rightarrow$ **81.0** $\rightarrow$ **54.4** $\rightarrow$ **27.8** $\rightarrow$ **20.0** 单调递减，Planning 最敏感（0.0-80.0），并行评估耗时 $\sim 15s$ (asyncio.gather)，成本 **¥0.012** (DeepSeek，对比 GPT-4o 低 27x)
- **多模型共识评估**：支持 DeepSeek + GLM-4 + Qwen-Plus 三厂商独立评分，输出 mean $\pm$ std（一致性指标），std > 15 告警高分歧；提供 Consensus API + EvaluationDetail 前端多模型对比柱状图
- **三种零侵入接入模式**：LangGraph Instrument（node 函数包装 + 自动 tool_calls 提取）、LLM Proxy（BaseChatModel 透明代理）、LangChain Callback（on_llm/tool 生命周期钩子），均一行代码；独立 SDK 包（sdk/），外部项目仅需 httpx + langchain-core

Wiki-Agent：AI 驱动的智能知识库系统 LangGraph / FastAPI / Vue3 / Milvus 2025.5 - 至今

- **多格式文档解析 + RecursiveCharacterTextSplitter 分块**：支持 Markdown/PDF/Word/TXT 自动识别与解析，LangChain RecursiveCharacterTextSplitter 分层分隔符（段落 $\rightarrow$ 句子 $\rightarrow$ 标点）分块（500 字符/50 重叠），替代手写 chunker，更稳健的语义边界保持
- **三级混合检索（20 条查询评估）**：Milvus 语义搜索（BGE-M3 + cosine）Top-1=**85.0%**/MRR=**0.91**，BM25 关键词（jieba + rank_bm25 + 25 词停用词表）Top-1=80.0%/MRR=0.85，Hybrid RRF 融合（k=60）Top-1=85.0%/MRR=0.87
- **4-Node StateGraph Agent**：search $\rightarrow$ respond $\rightarrow$ decide $\rightarrow$ execute，条件路由 + LangGraph interrupt 实现 Human-in-the-Loop CRUD 确认，AsyncSqliteSaver Checkpoint 中断恢复；PydanticOutputParser 驱动从对话自动提取知识（create/update/delete）

- **四路实时同步 + 向量管理后台**：Markdown → RecursiveCharacterTextSplitter 分块 → BGE-M3 Embedding → Milvus 向量库 + BM25 倒排索引 + Git 版本记录，增/改/删保持四路一致性，支持 commit 级回滚 + 一键全量重建；Vue3 + Element Plus 向量管理后台，可视化管理 Milvus 分块与元数据