

詹勇

(+86) 188-5660-3434 · 3446914219@qq.com · GitHub | CSDN @daetz-coder · 浙江-杭州

个人简介

计算机技术硕士在读，聚焦 **AI Agent** 系统设计、**RAG** 与 **LLM** 应用工程化。独立完成 Agent 运行时评估平台、RAG 知识库系统等全栈项目，熟悉 LangGraph 工作流编排、混合检索增强与 LLM-as-Judge 评估方法。

教育背景

浙江理工大学, 计算机技术硕士（在读） 2024.9 - 至今
一等优秀奖学金 (1 次), 二等优秀奖学金 (1 次)
嘉兴大学, 软件工程学士 2020.9 - 2024.6
校级优秀毕业生, 浙江省政府奖学金 (1 次), 学习优秀奖学金 (6 次)

学术成果

- **Yong Zhan**, Xiangyang Li, et al. "W-MSTC: A Window Based Multi-Scale Temporal Cross Attention Method for Few-Shot Modulation Recognition," *IEEE Communications Letters*, 2025. (第一作者)
- Congyuan Xu, **Yong Zhan**, et al. "Multimodal Fusion Based Few-Shot Network Intrusion Detection System," *Scientific Reports*, 2025. (第二作者)

技术能力

- **Agent / RAG**: LangGraph、StateGraph、Human-in-the-Loop、Checkpoint、Tool Calling、LLM-as-Judge、BM25、BGE-M3、RRF、ChromaDB
- **LLM 应用**: Prompt/Context/Harness Engineering、多模型评估对比、SSE 流式输出、Token 优化
- **全栈工程**: Python / FastAPI / Async SQLAlchemy / Pydantic / Vue3 / TypeScript / ElementPlus / ECharts / Git / Docker

项目经历

Agent Runtime Evaluation Platform：AI Agent 运行时质量评估平台 Python / FastAPI / LangGraph / Vue3 2025.3 - 至今

- **五维评估体系 (17 项子指标)**: Planning (覆盖度/顺序/粒度/完整性)、Tactical (相关性/效率/正确性)、Tool Use (选择质量/参数准确性/结果利用)、Memory (保持力/相关性/一致性)、Replan (触发适当性/适应质量/学习能力)，加权聚合 + 四档标定 ($\geq 80/\geq 60/\geq 40$ 优秀至较差)，6 条不同质量轨迹 $\times$ 5 评估器实测：综合分 **93.1 $\rightarrow$ 92.0 $\rightarrow$ 81.0 $\rightarrow$ 54.4 $\rightarrow$ 27.8 $\rightarrow$ 20.0** 单调递减，Planning 最敏感 (0.0-80.0)，单次全评估耗时 **71.1s/成本 ¥0.012** (DeepSeek, 对比 GPT-4o 低 27x)
- **三种零侵入接入模式**: LangGraph Instrument (node 函数包装 + 自动 tool_calls 提取)、LLM Proxy (BaseChatModel 透明代理)、LangChain Callback (on_llm/tool 生命周期钩子)，均一行代码；14 种轨迹动作类型 (plan/tool_call/state_change/replan 等)，状态变化自动 diff 计算
- **全链路可观测**: 线程安全轨迹采集器 (批量上传 + 失败回退缓冲)，ECharts 雷达图/趋势线/热力图/相关性矩阵 4 种可视化，SQL 按维度聚合分析 (AVG/MIN/MAX/分布)；对抗轨迹检测 (15 步纯 tool_call 得分仅 27.8)，Replan 场景评分 **85.2**

Wiki-Agent：AI 驱动的智能知识库系统 LangGraph / FastAPI / Vue3 / ChromaDB 2025.5 - 至今

- **三级混合检索 (20 条查询评估)**: Semantic (BGE-M3 + cosine) Top-1=**85.0%**/MRR=**0.91**, BM25 (jieba + rank_bm25 + 25 词停用词表)Top-1=80.0%/MRR=0.85, Hybrid RRF 融合 (k=60)Top-1=85.0%/MRR=0.87；三路并行按文档去重保留最高分 chunk
- **4-Node StateGraph Agent**: search $\rightarrow$ respond $\rightarrow$ decide $\rightarrow$ execute，条件路由 + LangGraph interrupt 实现 Human-in-the-Loop CRUD 确认，AsyncSqliteSaver Checkpoint 中断恢复；PydanticOutputParser 驱动从对话自动提取知识 (create/update/delete)
- **四路实时同步**: Markdown $\rightarrow$ 句边界感知 chunk (500 字符/50 重叠) $\rightarrow$ ChromaDB Embedding $\rightarrow$ BM25 倒排索引 $\rightarrow$ Git 版本记录，增/改/删保持四路一致性，支持 commit 级回滚 + 自动重索引
- **全栈交付**: FastAPI async + SSE 流式 (7 种事件类型)，Vue3 + Element Plus 前端集成 Markdown 渲染 + Git 版本历史浏览，Session 持久化 (SQLite 会话 + 消息 JSON)